

REGRESIÓN LINEAL: ALGUNOS ASPECTOS PRÁCTICOS



Mario I. Caicedo

3 de septiembre de 2021



REGRESIÓN≈PROBLEMA INVERSO


$$\mathbf{d}^{(obs)} = \mathbf{F}(\mathbf{m})$$



REGRESIÓN LINEAL

$$\mathbf{d} = \mathbf{F}\Theta$$

$$z_i = z_0 + a_i x_i + b_i y_i + a_{ij} x_i y_j + [\dots] + \epsilon_i$$



REGRESIÓN LINEAL

- El problema de **aprendizaje** consiste en encontrar (calcular) el vector de parámetros Θ
- La estructura de la solución comienza por la función de costo de mínimos cuadrados

$$J(\mathbf{m}) = (\mathbf{d}^{(obs)} - \mathbf{F}\mathbf{m})^T (\mathbf{d}^{(obs)} - \mathbf{F}\mathbf{m})$$

- El aprendizaje consiste en se reduce a minimizar la función de pérdida con respecto a los parámetros (\mathbf{m}).
- Solución analítica

$$\boxed{\mathbf{m} = (\mathbf{F}^T \mathbf{F})^{-1} \mathbf{F}^T \mathbf{d}^{(obs)}}$$



REGRESIÓN LINEAL (POLINOMIO DE SEGUNDO ORDEN DE UNA VARIABLE)

$$y = \theta_0 + \theta_1 x + \theta_2 x^2 \iff \mathbf{y} = \mathbf{F}\Theta$$

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_N \end{pmatrix}, \quad \mathbf{F} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ \vdots & \vdots & \vdots \\ 1 & x_N & x_N^2 \end{pmatrix}, \quad \Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix}$$



REGRESIÓN LINEAL MULTIVARIABLE (PLANO)

$$z = \theta_0 + \theta_1 x + \theta_2 y_1 \iff \mathbf{Z} = \mathbf{F}\Theta$$

$$\mathbf{Z} = \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ \vdots \\ z_N \end{pmatrix}, \quad \mathbf{F} = \begin{pmatrix} 1 & x_1 & y_1 \\ 1 & x_2 & y_2 \\ 1 & x_3 & y_3 \\ \vdots & \vdots & \vdots \\ 1 & x_N & y_N \end{pmatrix}, \quad \Theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix}$$



REGRESIÓN LINEAL MULTIVARIABLE (SUP. DE SGUNDO ORDEN) I

$$z = \theta_0 + \theta_1 x + \theta_2 y_1 + \theta_3 xy + \theta_4 x^2 + \theta_5 y^2 \iff \mathbf{Z} = \mathbf{F}\boldsymbol{\Theta}$$

$$\mathbf{Z} = \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ \vdots \\ z_N \end{pmatrix}, \quad \mathbf{F} = \begin{pmatrix} 1 & x_1 & y_1 & x_1y_1 & x_1^2 & y_1^2 \\ 1 & x_2 & y_2 & x_2y_2 & x_2^2 & y_2^2 \\ 1 & x_3 & y_3 & x_3y_3 & x_3^2 & y_3^2 \\ \vdots & \vdots & \vdots & & & \\ 1 & x_N & y_N & x_Ny_N & x_N^2 & y_N^2 \end{pmatrix}$$

$$\boldsymbol{\Theta} = (\theta_0 \quad \theta_1 \quad \theta_2 \quad \theta_3 \quad \theta_4 \quad \theta_5)^T$$



REGRESIÓN LINEAL (SUP. DE SEGUNDO ORDEN) II

$$\mathbf{F}^T = \begin{pmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_N \\ y_1 & y_2 & \dots & y_N \\ x_1y_1 & x_2y_2 & \dots & x_Ny_N \\ x_1^2 & x_2^2 & \dots & x_N^2 \\ y_1^2 & y_2^2 & \dots & y_N^2 \end{pmatrix}$$




REGRESIÓN LINEAL (SUP. DE SEGUNDO ORDEN) II

$$\mathbf{F}^T \mathbf{F} = \begin{pmatrix} N & \sum x_i & \sum y_i & \sum x_i y_i & \sum x_i^2 & \sum y_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i y_i & \sum x_i^2 y_i & \sum x_i^3 & \sum x_i y_i^2 \\ \sum y_i & \sum x_i y_i & \sum y_i^2 & \sum x_i y_i^2 & \sum y_i x_i^2 & \sum y_i^3 \\ \sum x_i y_i & \sum x_i^2 y_i & \sum x_i y_i^2 & \sum x_i^2 y_i^2 & \sum x_i^3 y_i & \sum x_i y_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^2 y_i & \sum x_i^3 y_i & \sum x_i^4 & \sum x_i^2 y_i^2 \\ \sum y_i^2 & \sum x_i y_i^2 & \sum y_i^3 & \sum x_i y_i^3 & \sum x_i^2 y_i^2 & \sum y_i^4 \end{pmatrix}$$

Note que esta matriz es simétrica y definida no negativa



DESCENSO POR GRADIENTE



- La solución estándar consiste en minimizar la función de costo a través de la técnica de **Descenso por Gradiente**.



DESCENSO POR GRADIENTE

- LOSS

$$J(\Theta) = (\mathbf{d}^{(obs)} - \mathbf{F}\Theta)^T(\mathbf{d}^{(obs)} - \mathbf{F}\Theta)$$

- GRADIENTE

$$\nabla_{\Theta^T} J(\Theta) = -\mathbf{F}^T(\mathbf{d}^{(obs)} - \mathbf{F}\Theta)$$

- ITERACIÓN

$$\Theta^{(k+1)} = \Theta^{(k)} - \mu \nabla_{\Theta^T} J(\Theta^{(k)})$$

- Veamos como funciona toda esta teoría

